⚙️ Konfiguracja

Silnik LLM: **OpenAI** (najpewniejszy tool calling).

Model OpenAI

gpt-4.1

OPENAI_API_KEY

••

🎨 Wizualizacje

Podgląd 3D (py3Dmol)

Kolorowanie 3D

- (•) Pierwiastki
- ( ) Ładunki (Gasteiger)

🧪 BRD4 Activity Predictor + Asystent LLM

Podaj SMILES lub zapytaj o cząsteczkę w języku naturalnym. LLM sam wywoła model GNN i narzędzia RDKit.

💬 Asystent | 📊 Prezentacja projektu

📊 Predykcja aktywności małych cząsteczek wobec BRD4

Projekt QSAR: na bazie **ChEMBL 36** budujemy model regresji **pIC50** dla pojedynczego celu białkowego **BRD4** (`CHEMBL1163125` , bromodomena — cel onkologiczny), a następnie udostępniamy go przez asystenta LLM z **function calling** i narzędziami RDKit.

R^2 (scaffold)	R^2 (random)	RMSE (scaffold)	Próg projektu
0.64	0.74	0.74	$R^2 > 0.5$

1) Problem i cel

- **Zadanie:** przewidzieć aktywność biologiczną związku — siłę inhibicji BRD4 (pIC50 = $-\log_{10}$ IC50[M]).
- **Dlaczego pIC50:** rozkład IC50 rozciąga się na rzędy wielkości; skala log jest stabilna numerycznie i standardowa w QSAR.
- **Dlaczego jeden target:** model globalny (≈2900 celów) dawał niskie R^2 (~0.18, RF); prosty GCN na wszystkich targetach ~0.06. Zawężenie do BRD4 zamienia problem w spójne single-target QSAR.

2) Dane, pipeline i EDA

Z ChEMBL 36 wyekstrahowaliśmy **~1,5 mln** pomiarów IC50/Ki; po czyszczeniu zostało **~1,44 mln** wierszy, a po agregacji medianą do pary związek–target — **~1,05 mln** obserwacji dla **~2900** celów.

Modelowanie BRD4 (sekcja 8.2b): **7689** pomiarów IC50 z poprawnymi SMILES, **~8821** par związek–target, **~3200** unikalnych scaffoldów Murcko.

Integralność pipeline'u — trzy naprawione wycieki:

- **Wyciek cech** — usunięto [illegible] (zawierały pIC50 we wzorze:

- **Wyciek cech** — usunięto `pIC50`, `set`, `te`, `tte` (zawierały pIC50 we wzorze, fałszywe $R^2 \approx 0.999$).
- **Wyciek obserwacji** — agregacja medianą pomiarów tej samej pary związek–target.
- **Wyciek związków** — GroupShuffleSplit / scaffold split (ten sam związek nie trafia jednocześnie do train i test).

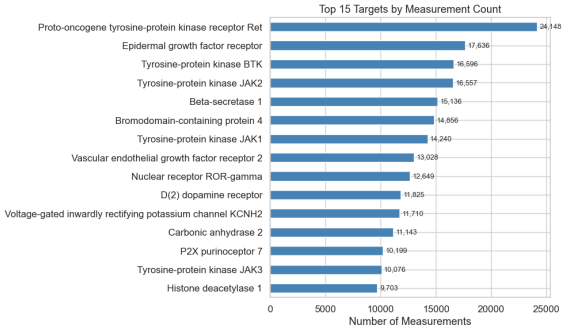

EDA (cała baza): top 15 celów — BRD4 (#6, ~14,9 tys. pomiarów) to dobrze zbadany target.

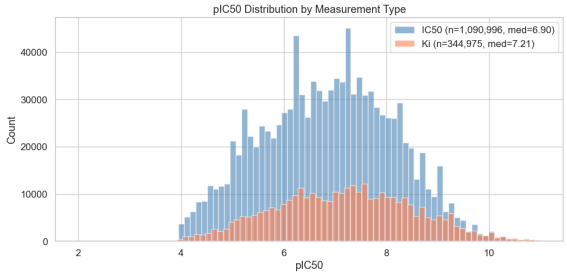

EDA (cała baza): rozkład pIC50 — dominacja IC50; Ki ma nieco wyższą medianę.

3) Metodyka modelowania

- **MLP (Morgan/ECFP, 2048 bit):** baseline na odciskach palca cząsteczki.
- **GIN (edge-aware, GINEConv):** graf z 33 cechami atomu i 7 cechami wiązań, BatchNorm + Dropout + połączenia rezydualne (następca słabego GCN z 5 cechami atomu).
- **Dwa podziały:** *random* 80/10/10 oraz *scaffold* Murcko (uczciwa ocena na

nowych rdzeniach).

- **Metryki:** R^2, RMSE/MAE oraz **błąd krotności IC50** = 10^RMSE (np. RMSE=0.74 → ~×5.5).
- **Funkcja straty:** MSE vs Huber (δ=1.0) — Huber wygrywa na wszystkich metrykach GIN.

4) Wyniki

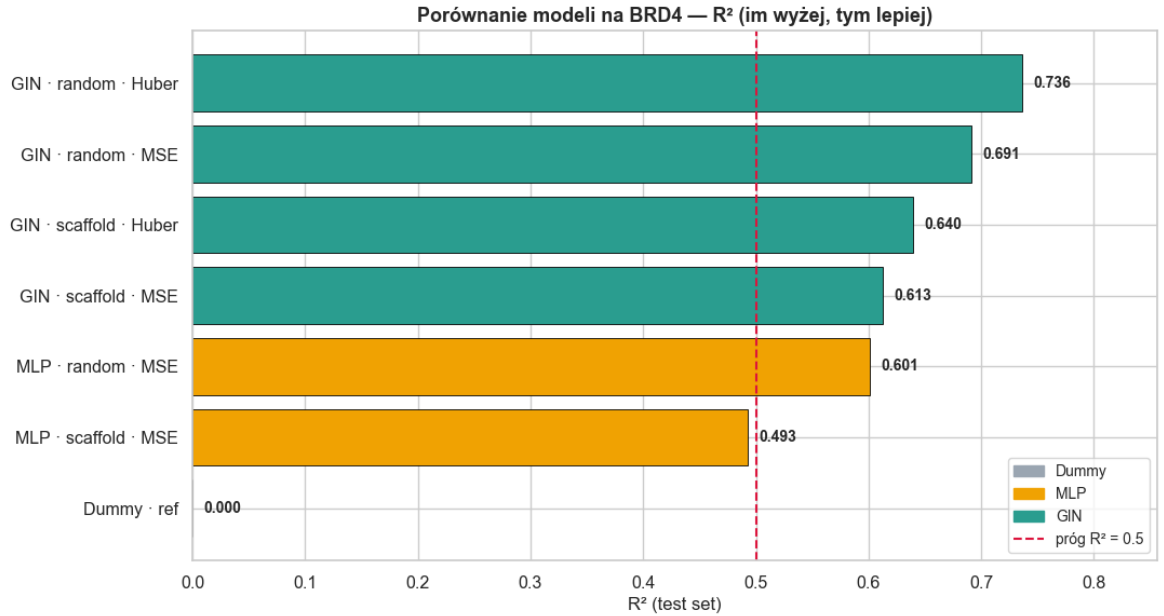

Porównanie R^2 na BRD4 — wszystkie warianty GIN > 0.5; MLP scaffold (0.49) poniżej progu.

› Tabela metryk (sekcja 9.16 notebooka)

GNN Baseline — Learning Curves & Predicted vs Actual

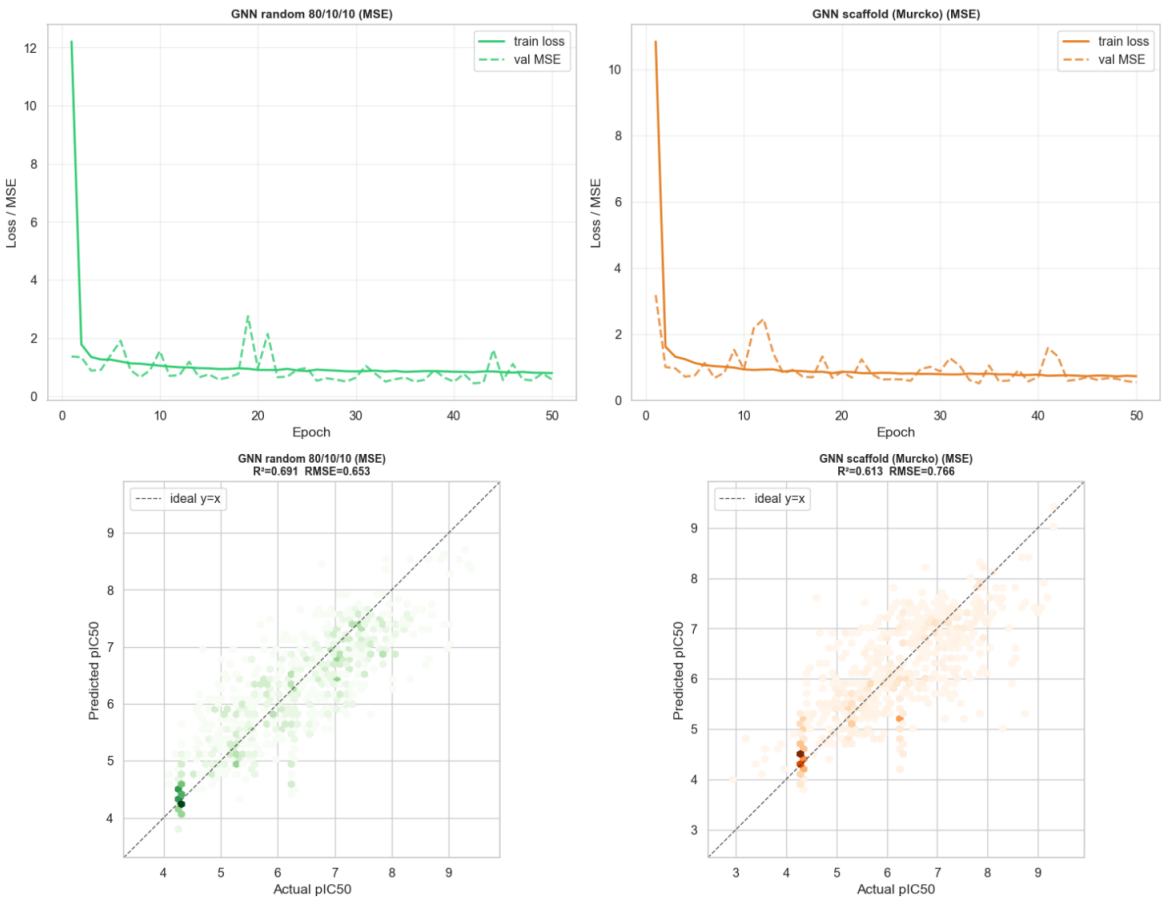

GIN (MSE): krzywe uczenia + pred vs actual — random (R^2=0.69) i scaffold (R^2=0.61).

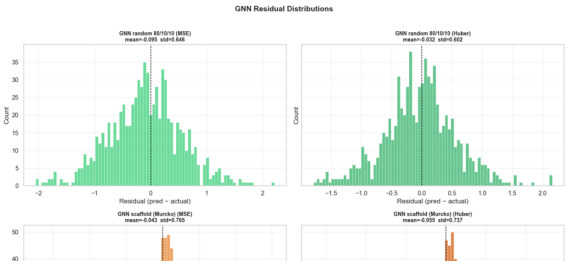

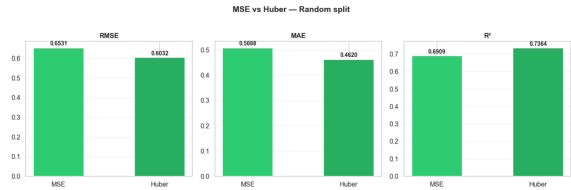

MSE vs Huber — random split (Huber lepszy

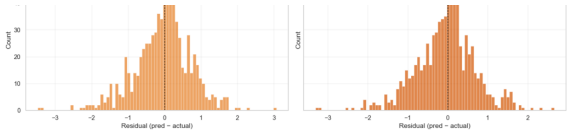

GIN: rozkład reszt — random vs scaffold, MSE vs Huber (4 konfiguracje).

na RMSE, MAE i R^2).

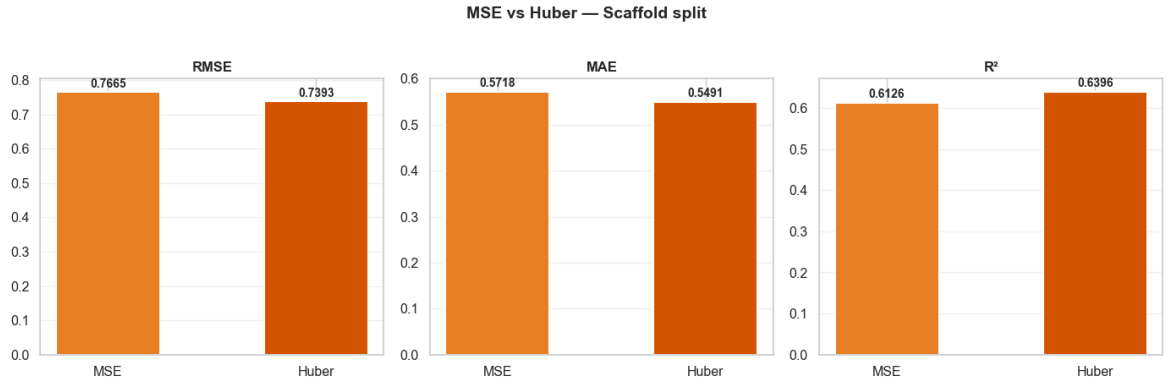

MSE vs Huber — scaffold split (Murcko); Huber również wygrywa.

› Baseline MLP (Morgan FP) — pełna wizualizacja z sekcji 8.17

5) Analiza błędów (mismatch analysis)

Analiza na **scaffold splicie + MSE** (najtrudniejszy scenariusz, nowe rdzenie w teście). Model ma tendencję do **zaniżania najsilniejszych inhibitorów** (regresja do średniej).

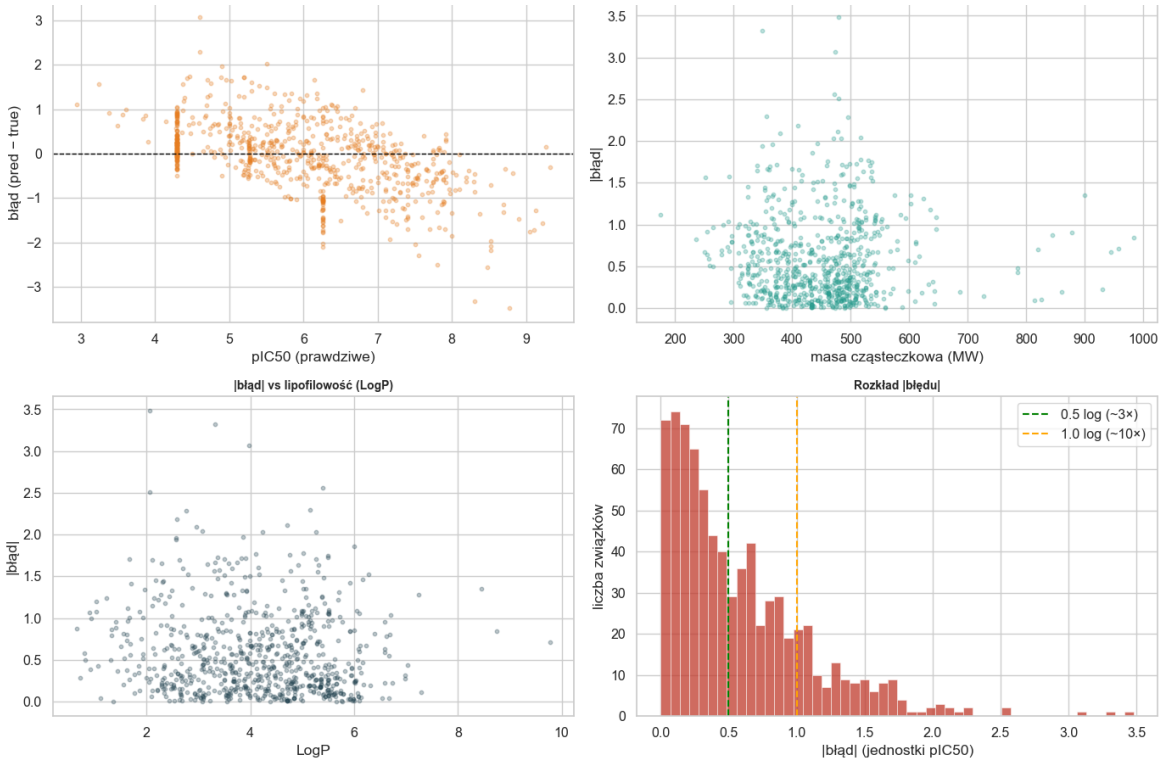

Bias vs pIC50, błąd vs MW/LogP, rozkład |błędu| z progami 0.5 i 1.0 log.

Kalibracja (scaffold test, n=769): **55%** predykcji w granicy 0.5 log (≈ ×3 IC50), **82%** w granicy 1.0 log (≈ ×10), mediana |błędu| ≈ **0.42**, bias ≈ **−0.04** (niewielkie zaniżanie).

6) Wnioski

- **GIN > MLP** na BRD4; wszystkie warianty GIN przekraczają próg R^2>0.5, MLP na scaffold split — nie (R^2≈0.49).

- **Model produkcyjny:** GIN + Huber, random split (R^2≈0.74); jakość na nowych rdzeniach potwierdza scaffold Huber (R^2≈0.64).
- **Niepewność** (MC Dropout) i **błąd krotności IC50** dają praktyczną interpretację predykcji.
- **Aplikacja LLM** łączy model z narzędziami RDKit: plan → wywołania → interpretacja, z wizualizacjami 2D/3D, mapą podobieństwa do JQ1 (referencyjny inhibitor) i licznikiem kosztów.

Wykresy wyeksportowane z notebooka analitycznego (analysis.ipynb, sekcje 5–9).

Wpisz SMILES lub pytanie…